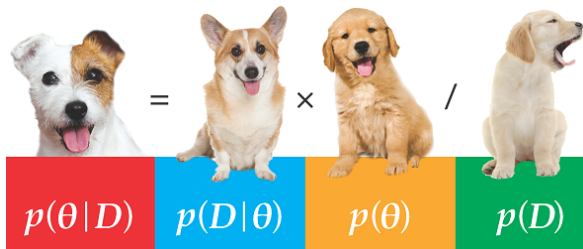


# Importance Sampling appliqué à la régression Bridge Bayésienne

Gautier Appert

Stage ENSAE ParisTech 2A

16 décembre 2015


$$p(\theta|D) = p(D|\theta) \times p(\theta) / p(D)$$

## Référence

- *The Bayesian Bridge (2014)*, Nicholas G. Polson, James G. Scott, Jesse Windle <sup>a</sup>.
- Utilisation d'un **Gibbs Sampler** s'appuyant sur la structure hiérarchique du modèle Bridge bayésien.
- Package "**BayesBridge**" sur R associé à l'article.

---

a. Lien arXiv : <http://arxiv.org/pdf/1109.2279v2.pdf>

## Objectif

- Utilisation d'une méthode beaucoup plus simple appelée **Importance Sampling**.
- Reproduire les résultats (applications) de l'article avec cette méthode et comparaison.
- Limites de l'importance sampling lorsque la dimension du modèle augmente  $\Rightarrow$  **SMC tempering**.

# Régression Bridge

## Modèle

- Modèle linéaire Gaussien :  $y = X\beta + \epsilon$
- $\epsilon \sim \mathcal{N}(0_{\mathbb{R}^n}, \sigma^2 I_n)$
- $X = [x^1 | \dots | x^p] \in \mathcal{M}_{n,p}(\mathbb{R})$ ,  $\beta \in \mathbb{R}^p$  et  $y \in \mathbb{R}^n$

## Régression Bridge

$$\begin{aligned} \mathcal{P}_\delta : \min_{\beta} \quad & \|y - X\beta\|_2^2 \\ \text{s.c.} \quad & \sum_{j=1}^p |\beta_j|^\alpha \leq \delta \end{aligned}$$


où le paramètre  $\alpha \in [0, 1]$

## Remarques


- Pour  $\alpha < 1$  le problème n'est pas **convexe** contrairement à la régression Ridge ou Lasso
- $\alpha = 1 \Rightarrow$  fournit la pénalisation **Lasso** (le pb devient convexe).
- $\alpha = 0 \Rightarrow$  la régression sur les meilleurs sous-ensembles des variables,  $\{\mathcal{M}_k \in \mathcal{P}(\{1, \dots, p\}) | k \in \llbracket 1; p \rrbracket\}$ .

## Représentation graphique de la pénalisation


$\alpha > 2$




$\alpha = 2$



$\alpha = 1$



$\alpha < 1$



Fonction objectif (Lagrangien),  $\alpha \in [0, 1]$  et  $\nu \in \mathbb{R}_+$

$$\hat{\beta}_{bridge}(\nu) \in \arg \min_{\beta} \mathcal{L}_y(\beta, \nu) \triangleq \frac{1}{2\sigma^2} \|y - X\beta\|_2^2 + \nu \sum_{j=1}^p |\beta_j|^\alpha$$

## Remarques

- Les Problèmes  $\mathcal{P}_\delta$  et  $\min_{\beta} \mathcal{L}_y(\beta, \nu)$  sont équivalents.
- Le problème n'est pas convexe  $\Rightarrow$  problème d'optimisation plus difficile d'un point de vue numérique.
- Le passage dans une formulation bayésienne du modèle peut donc être un moyen de palier ce problème.

## Loi a priori dans le modèle Bridge bayésien

- On impose la loi a priori suivante sur  $\beta = (\beta_1, \dots, \beta_p)'$  :

$$\pi(\beta|\alpha, \nu) = \prod_{j=1}^p \pi(\beta_j|\alpha, \nu) \propto \prod_{j=1}^p \exp\{-\nu|\beta_j|^\alpha\} \propto \exp\left\{-\nu \sum_{j=1}^p |\beta_j|^\alpha\right\}$$

## Remarques

- Chaque  $\beta_j$  suit une loi **normale généralisée** :  $f(x) = K \exp\left\{-\frac{|x-\mu|^\alpha}{\sigma}\right\} 1_{\mathbb{R}}(x)$
- La constante de normalisation est calculable :  $\mathcal{K}(\alpha, \nu) = \frac{\alpha \cdot \nu^{1/\alpha}}{2 \cdot \Gamma(1/\alpha)}$ .
- Cet a priori peut être vu comme un mélange (continue) de Gaussiennes <sup>b</sup> :


$$\exp\{-|z|^q\} \propto \int_0^\infty \frac{1}{\sqrt{2\pi s}} \exp\left\{-\frac{z^2}{2s}\right\} g(s) ds$$

---

b. Théorème de Bernstein sur les fonctions totalement monotones (Article).

# Régression Bridge Bayésienne

Densité gaussienne et plot de la densité a priori :  $f(x) = \frac{\alpha}{2\tau\Gamma(\frac{1}{\alpha})} \exp(-(\frac{|x|}{\tau})^\alpha)$



alpha=0.7 tau = 1 n=1000

# Régression Bridge Bayésienne

## Vraisemblance du modèle linéaire Gaussien

$$L(y|\beta, \sigma^2) \propto \exp \left\{ -\frac{1}{2\sigma^2} \|y - X\beta\|_2^2 \right\}.$$

## La distribution a posteriori de $\beta$ (formule de Bayes)

$$\pi(\beta|y, \sigma^2, \alpha, \nu) \propto L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu) \propto \exp\{-\mathcal{L}_y(\beta, \nu)\}.$$

## Remarques

- Maximiser la densité a posteriori  $\pi(\beta|y, \sigma^2, \alpha, \nu)$  est équivalent à maximiser le Lagrangien  $\mathcal{L}_y(\beta, \nu)$  du problème  $\mathcal{P}_\delta$ .
- la densité a posteriori n'est pas une loi connue  $\Rightarrow$  Gibbs Sampler, **Importance Sampling**, **SMC tempering**, ...

## Estimation Bayésienne

- $\hat{\beta}_{map} \stackrel{\text{def}}{\in} \arg \max_{\beta} \pi(\beta|y, \sigma^2, \alpha, \nu) = K(y, \sigma^2, \alpha, \nu) \cdot \exp\{-\mathcal{L}_y(\beta, \nu)\}$
- $\hat{\beta}_{Bayes} = \mathbb{E}_{\beta|y, \sigma^2, \alpha, \nu}^{\pi}[\beta|y, \sigma^2, \alpha, \nu] = \int_{\mathbb{R}^p} \beta \cdot \pi(\beta|y, \sigma^2, \alpha, \nu) \, d\beta.$



# Régression Bridge Bayésienne

Cadre plus général avec les paramètres  $\sigma^2$ ,  $\alpha$  et  $\nu$  inconnus.

Le Bridge vu comme un **Modèle Hiérarchique Bayésien**

- $y|\beta, \sigma^2 \sim \mathcal{N}(X\beta, \sigma^2 I_n) \equiv$  vraisemblance
- $\beta|\alpha, \nu \sim \pi(\cdot|\alpha, \nu) \equiv$  a priori
- $\alpha, \nu \sim \pi(\cdot, \cdot) \equiv$  hyper a priori

Formule de Bayes dans le cas d'un **Modèle Hiérarchique Bayésien**

$$\pi(\beta, \alpha, \nu, \sigma^2 | y) \propto L(y|\beta, \sigma^2) \pi(\beta|\alpha, \nu) \pi(\alpha) \pi(\nu) \pi(\sigma^2)$$

**Espérance a posteriori**

$$\begin{aligned} & \mathbb{E}_{\beta, \alpha, \nu, \sigma^2 | y}^{\pi} [h(\beta, \alpha, \nu, \sigma^2) | y] \\ & \propto \int_{\Theta} h(\beta, \alpha, \nu, \sigma^2) L(y|\beta, \sigma^2) \pi(\beta|\alpha, \nu) \pi(\alpha) \pi(\nu) \pi(\sigma^2) d\alpha d\nu d\sigma^2 d\beta \end{aligned}$$

# Importance Sampling

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

On s'intéresse à l'estimation de quantités sous la forme d'**espérance a posteriori**.

## Estimation bayésienne

Soit  $h : \mathbb{R}^p \rightarrow \mathbb{R}^q$  :

$$\begin{aligned}\mathcal{I}(\alpha, \nu, \sigma^2) &= \mathbb{E}_{\beta|y, \sigma^2, \alpha, \nu}^{\pi} [h(\beta)|y, \sigma^2, \alpha, \nu] = \int_{\mathbb{R}^p} h(\beta) \cdot \pi(\beta|y, \sigma^2, \alpha, \nu) \, d\beta \\ &= \frac{\int_{\mathbb{R}^p} h(\beta) \cdot L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu) \, d\beta}{\int_{\mathbb{R}^p} L(y|\beta, \sigma^2) \pi(\beta|\alpha, \nu) \, d\beta}\end{aligned}$$

## Importance Sampling

Soit  $q : \mathbb{R}^p \rightarrow \mathbb{R}^+$  une densité instrumentale (**proposal**) facile à simuler :

$$\mathcal{I}(\alpha, \nu, \sigma^2) = \frac{\int_{\mathbb{R}^p} h(\beta) \cdot \frac{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)}{q(\beta)} \cdot q(\beta) \, d\beta}{\int_{\mathbb{R}^p} \frac{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)}{q(\beta)} \cdot q(\beta) \, d\beta} = \frac{\mathbb{E}_q \left( h(\beta) \cdot \frac{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)}{q(\beta)} \right)}{\mathbb{E}_q \left( \frac{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)}{q(\beta)} \right)}$$

# Importance Sampling

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

## Poids d'importance

On pose :

$$\omega(\beta) = \frac{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)}{q(\beta)}$$

## Importance Sampling (suite)

$$\mathcal{I}(\alpha, \nu, \sigma^2) = \frac{\mathbb{E}_q(h(\beta) \cdot \omega(\beta))}{\mathbb{E}_q(\omega(\beta))}$$

Estimateur auto-normalisé :

$$\hat{\mathcal{I}}_{\text{AIS}} = \frac{\sum_{k=1}^N h(\beta^{(k)}) w(\beta^{(k)})}{\sum_{k=1}^N w(\beta^{(k)})} \xrightarrow{\text{p.s.}} \mathcal{I}(\alpha, \nu, \sigma^2)$$

Avec  $\{\beta^{(1)}, \dots, \beta^{(N)}\} \stackrel{\text{iid}}{\sim} q$ .

Justification basée sur la **loi forte des grands nombres** et la **Delta-Méthode**.

# Importance Sampling

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

## Importance Sampling (suite)

- On peut obtenir une estimation non paramétrique des densités a posteriori marginales à l'aide de l'estimateur **Parzen Rosenblatt** sur l'échantillon pondéré  $\{\beta^{(k)}, \omega(\beta^{(k)})\}_{k=1}^N$ .
- Resampling** des  $\{\beta^{(k)}\}_{k=1}^N$  suivant la distribution empirique :

$$\hat{\pi}(\tilde{\beta}) = \sum_{k=1}^N \omega(\beta^{(k)}) \cdot \delta_{\beta^{(k)}}(\tilde{\beta}) \approx \pi(\beta|y)$$

## Comment choisir la fonction d'importance $q(\beta)$ ?

- Fonction d'importance minimisant la variance asymptotique :  $q_{opt}(\beta) \propto \pi(\beta|y) \cdot |h(\beta) - \mathcal{I}| \Rightarrow$  pas d'intérêt pratique.
- Condition de support :  $\text{supp}\{q(\beta)\} \supset \text{supp}\{h(\beta)L(y|\beta, \sigma^2)\pi(\beta|\alpha, \nu)\}$ .
- Faire en sorte que les poids  $w(\beta) = \frac{L(y|\beta)\pi(\beta|\alpha, \nu)}{q(\beta)}$  soit bornés  $\Rightarrow$  estimateur à variance asymptotique finie.
- $q$  facilement simulable à l'aide d'un générateur rapide et fiable.
- Choisir une fonction d'importance  $q$  qui "s'approche" le plus possible de la densité a posteriori.

# Importance Sampling

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

## Astuce typique dans les modèles linéaires bayésiens

- Si l'on impose une loi a priori impropre  $\pi(\beta|\alpha, \nu) = 1$ .
- On obtient  $\pi(\beta|y, \sigma) \propto L(y|\beta, \sigma^2) \propto \exp\{-\frac{1}{2\sigma^2} \|y - X\beta\|_2^2\}$ .
- Or il est possible de vérifier que la vraisemblance  $L(y|\beta, \sigma^2)$  est équivalente en  $\beta$  à la densité de la loi normale multivariée  $\mathcal{N}\{\hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\}$ .

## Fonction instrumentale

- On peut donc proposer comme fonction instrumentale la densité de la loi normale multivariée,  $q(\beta) = \mathcal{N}\{\beta|\hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\}$ , facilement simulable sur  $\mathbf{R}$  à l'aide du package **mvtnorm**.

# Importance Sampling

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

## Poid d'importance

On pose :

$$w(\beta) = \frac{L(y|\beta, \sigma^2)\pi(\beta|\alpha, \nu)}{\mathcal{N}\{\beta|\hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\}} \propto \pi(\beta|\alpha, \nu).$$

les poids sont bornés par :  $\max_{\beta} \pi(\beta|\alpha, \nu) = \pi(0|\alpha, \nu) = \frac{\alpha^p \cdot \nu^{p/\alpha}}{2^p \cdot [\Gamma(1/\alpha)]^p}.$

## Estimateur AIS

On peut alors employer l'estimateur autonormalisé pour l'estimation de  $\mathcal{I}(\alpha, \nu, \sigma^2)$  :

$$\hat{\mathcal{I}}_{\text{AIS}} = \frac{\sum_{k=1}^N h(\beta^{(k)})\pi(\beta^{(k)}|\alpha, \nu)}{\sum_{k=1}^N \pi(\beta^{(k)}|\alpha, \nu)}$$

Où  $\{\beta^{(1)}, \dots, \beta^{(N)}\} \stackrel{iid}{\sim} \mathcal{N}\{\hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\}.$

# Importance Sampling

Critère pour mesurer l'efficacité de l'importance sampling

**Critère ESS** (*taille effective d'échantillon*)

$$\text{ESS} \stackrel{\text{def}}{=} \frac{\left\{ \sum_{k=1}^N \omega(\beta^{(k)}) \right\}^2}{\sum_{k=1}^N \omega(\beta^{(k)})^2} \in \llbracket 1; N \rrbracket$$

**Critère EF** (*facteur d'efficacité*)

$$\text{EF} = \text{ESS}/N \equiv \text{ESS}\%$$





TABLE : ESS en % dans le cas où  $\alpha$ ,  $\nu$  et  $\sigma^2$  sont fixés.

	Diabete	Ozone	Boston
EF	13%	90%	93%

# Application sur les données du diabète

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

On fixe  $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{\epsilon}_i^2$  et  $\alpha = 0.5$ ,  $\nu = 4.5$ .









# Application sur les données du diabète

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés



On fixe  $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{\epsilon}_i^2$  et  $\alpha = 0.5$ ,  $\nu = 4.5$ .



# Application sur les données du diabète

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés


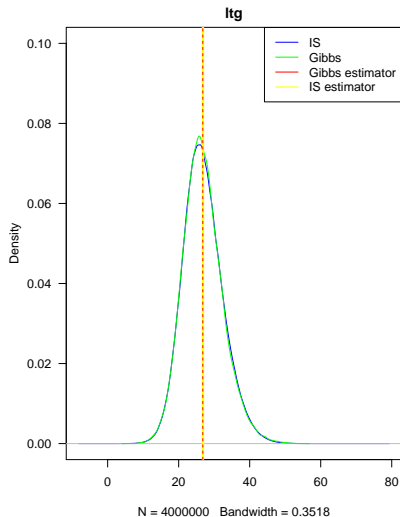
On fixe  $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{\epsilon}_i^2$  et  $\alpha = 0.5$ ,  $\nu = 4.5$ .



# Application sur les données du diabète

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

On fixe  $\hat{\sigma}^2 = \frac{1}{n} \sum \hat{\epsilon}_i^2$  et  $\alpha = 0.5$ ,  $\nu = 4.5$ .



# Importance Sampling

## Problème de la dimension

Comment se comporte la méthode importance sampling lorsque la dimension du modèle augmente ?

### Traitement préalable des DATA *Boston* et *Ozone*

- On ajoute toutes les variables croisées  $(x^i \cdot x^j)_{i \neq j}$  et carrées  $(x^i)^2$ .
- On obtient **103** variables explicatives pour la base *Boston*.
- On obtient **54** variables explicatives pour la base de données *Ozone*.

TABLE : EF lorsque la dimension du modèle augmente.

	Boston	Ozone
EF	0.001%	0.001%

### Variance des poids

$$\mathbb{V}_g(\omega(\beta)) = \mathbb{E}_g[\omega(\beta)^2] - \mathbb{E}_g^2[\omega(\beta)].$$

$$\mathbb{E}_g[\omega(\beta)^2] \geq 1 \iff \prod_{j=1}^p \mathbb{E}_g \left( \frac{f_1(\beta_j)}{g_1(\beta_j)} \right) \geq 1 \iff C^p \geq 1.$$

# Monte Carlo Séquentiel

## Rappel de la problématique

- On souhaite simuler les paramètres  $\beta^{(k)}$ , appelés "**particules**", suivant la distribution cible  $\pi(\beta|y, \alpha, \nu, \sigma^2) \propto L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)$ .

## Remarques

- Les données ne possèdent pas de temporalité.
- Comment appliquer l'Algorithme SMC dans notre **problème statique** ?

## Création (artificielle) d'une séquence de distribution : SMC tempering

- On définit une séquence de distribution pour tout  $t \in \llbracket 1; T \rrbracket$ ,
$$\pi_t(\beta) \propto q(\beta)^{1-\gamma_t} \{L(y|\beta, \sigma^2) \cdot \pi(\beta|\alpha, \nu)\}^{\gamma_t}$$
- $q(\beta) \equiv$  **proposal**.
- On définit  $(\gamma_t)_{t \in \llbracket 1; T \rrbracket}$  tel que  $\gamma_0 = 0 < \gamma_1 < \dots < \gamma_T = 1$ , suite croissante appelée "**la température**".

## Propriété directe

- $\pi_0(\beta) \propto q(\beta)$  (**proposal**)
- $\pi_T(\beta) \propto \pi(\beta|y, \alpha, \nu, \sigma^2)$  (**distribution a posteriori**)

# SMC tempering

Paramètre  $\sigma^2$  et hyperparamètres  $\alpha$  et  $\nu$  fixés

## Choix du proposal $q(\beta)$ ?

- $q(\beta) = \mathcal{N}\{\beta | \hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\}$ .
- Dans le cas où  $\sigma^2$  est fixé  $\Rightarrow$  simplifications avec la vraisemblance  $L(y|\beta, \sigma^2)$ .
- On obtient la séquence de distribution suivante :

$$\pi_t(\beta) \propto \mathcal{N}\{\beta | \hat{\beta}_{\text{ols}}, \mathbb{V}(\hat{\beta}_{\text{ols}})\} \cdot \pi(\beta | \alpha, \nu)^{\gamma_t}.$$

## Propriété

- La séquence de distribution  $\pi_t(\beta)$  permet d'atteindre la distribution cible  $\pi(\beta|y, \alpha, \nu, \sigma^2)$  au fur et à mesure.
- Evolution de la distribution auxiliaire,  
 $\pi_0(\beta) \longrightarrow \dots \longrightarrow \pi_t(\beta) \longrightarrow \pi_{t+1}(\beta) \longrightarrow \dots \longrightarrow \pi_T(\beta)$ .

## Algorithme SMC tempering avec $\alpha, \sigma^2, \nu$ fixés

Initialisation ( $t=0$ ) :

- $\beta^{(1)}, \dots, \beta^{(N)} \sim \mathcal{N}(\beta | \hat{\beta}_{ols}, \sigma^2(X^T X)^{-1})$  (proposal)

For  $t=1$  to  $T$  :

- **Poids** :  $\omega_t(\beta^{(k)}) = \frac{\pi_t(\beta^{(k)})}{\pi_{t-1}(\beta^{(k)})} \propto \exp\{-(\gamma_t - \gamma_{t-1}) \cdot \nu \sum_{j=1}^p |\beta_j|^\alpha\}$  (poids des particules)
- **Resampling** :  $\mathbb{P}(\hat{\beta}^{(k)} = \beta^{(k)}) = \frac{\omega_t(\beta^{(k)})}{\sum_k \omega_t(\beta^{(k)})}$  (weighted bootstrap)
- **Mutation/Move** : MCMC Hastings par marche aléatoire :  $\xi^{(k)} = \hat{\beta}^{(k)} + \epsilon$  où  $\epsilon \sim \mathcal{N}(0, \mathbb{V}(\hat{\beta}) \cdot \kappa)$  avec  $\kappa = 0.05$

$$\tilde{\beta}^{(k)} = \begin{cases} \xi^{(k)} & \text{avec probabilité } \rho(\xi^{(k)}, \hat{\beta}^{(k)}) = \min \left\{ 1, \frac{\pi_t(\xi^{(k)})}{\pi_t(\hat{\beta}^{(k)})} \right\} \\ \hat{\beta}^{(k)} & \text{avec probabilité } 1 - \rho(\xi^{(k)}, \hat{\beta}^{(k)}) \end{cases}$$

End For

Return :  $\tilde{\beta}$

# Monte Carlo Séquentiel

## Propriété

- A chaque itération on simule suivant la distribution empirique :

$$\hat{\pi}_t(\tilde{\beta}) = \sum_{k=1}^N \omega_t(\beta^{(k)}) \cdot \delta_{\beta^{(k)}}(\tilde{\beta}) \approx \pi_t(\tilde{\beta})$$

- A l'itération  $t = T$  on a :

$$\hat{\pi}_T(\tilde{\beta}) = \sum_{k=1}^N \omega_T(\beta^{(k)}) \cdot \delta_{\beta^{(k)}}(\tilde{\beta}) \approx \pi(\beta|y, \alpha, \nu, \sigma^2)$$

Amélioration : comment choisir la séquence  $(\gamma_t)_{t \in [1; T]}$  ?

Algorithme **SMC tempering Adaptatif** avec  $\alpha, \sigma^2, \nu$  fixés

Au lieu de choisir une suite  $(\gamma_t)_t$  arbitraire il est possible de rendre l'algorithme SMC **adaptatif** en résolvant à chaque itération  $t$  l'équation suivante en  $\gamma$  :

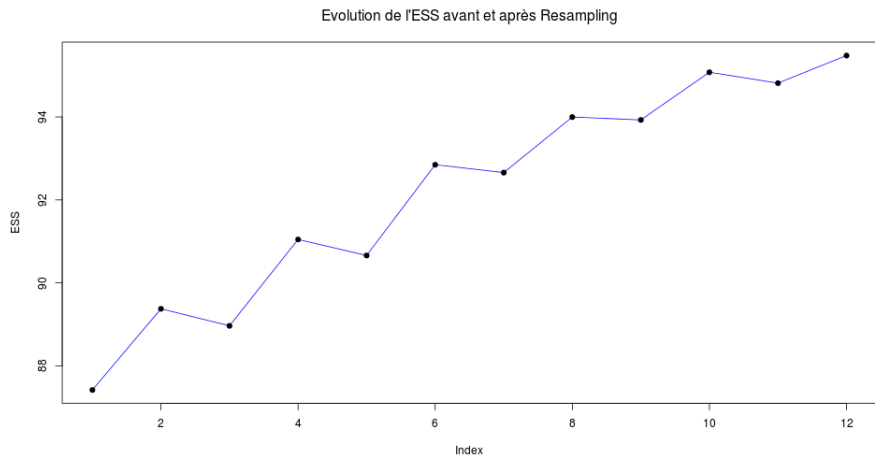
$$\mathbb{EF}(\gamma) = 98\%$$

Il est possible de prendre une autre valeur supérieure à 98%.



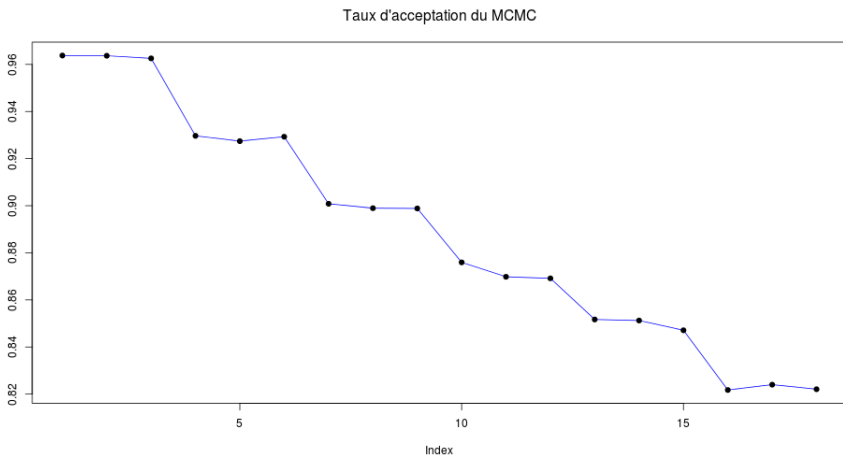
# Diabete Data : résultats dans le cas particulier où $\sigma^2$ , $\alpha$ et $\nu$ sont fixés

$(\gamma_t)_{t \in [1; T]} = [0; 0.2; 0.4; 0.6; 0.8; 1]$  et  $\alpha = 0.5$ ,  $\nu = 4.5$  et  $\hat{\sigma}^2 = \hat{\sigma}_{ML}^2$



# Diabete Data : résultats dans le cas particulier où $\sigma^2$ , $\alpha$ et $\nu$ sont fixés

$(\gamma_t)_{t \in [1; T]} = [0; 0.2; 0.4; 0.6; 0.8; 1]$  et  $\alpha = 0.5$ ,  $\nu = 4.5$  et  $\hat{\sigma}^2 = \hat{\sigma}_{ML}^2$




# Diabète Data : résultats dans le cas particulier où $\sigma^2$ , $\alpha$ et $\nu$ sont fixés


$(\gamma_t)_{t \in [1; T]} = [0; 0.2; 0.4; 0.6; 0.8; 1]$  et  $\alpha = 0.5$ ,  $\nu = 4.5$  et  $\hat{\sigma}^2 = \hat{\sigma}_{ML}^2$




N = 50000 Bandwidth = 0.2265



N = 50000 Bandwidth = 0.3066



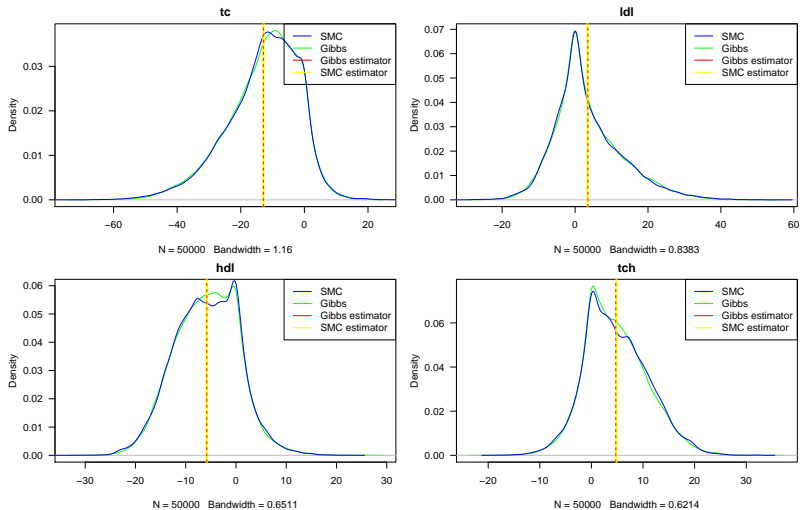
N = 50000 Bandwidth = 0.3262



N = 50000 Bandwidth = 0.3234


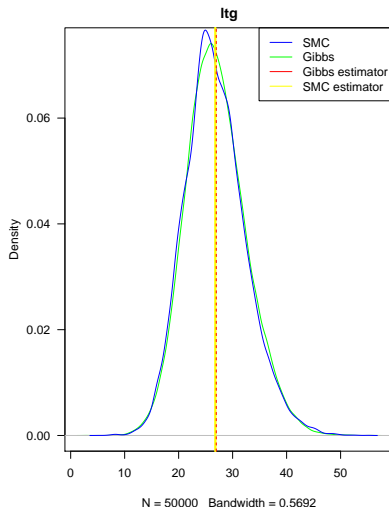
# Diabete Data : résultats dans le cas particulier où $\sigma^2$ , $\alpha$ et $\nu$ sont fixés

$(\gamma_t)_{t \in [1; T]} = [0; 0.2; 0.4; 0.6; 0.8; 1]$  et  $\alpha = 0.5$ ,  $\nu = 4.5$  et  $\hat{\sigma}^2 = \hat{\sigma}_{ML}^2$



# Diabete Data : résultats dans le cas particulier où $\sigma^2$ , $\alpha$ et $\nu$ sont fixés

$(\gamma_t)_{t \in [1; T]} = [0; 0.2; 0.4; 0.6; 0.8; 1]$  et  $\alpha = 0.5$ ,  $\nu = 4.5$  et  $\hat{\sigma}^2 = \hat{\sigma}_{ML}^2$



Considérer le cas général avec  $\sigma^2$ ,  $\alpha$  et  $\nu$  inconnus

- Importance sampling avec hyperprior sur  $\alpha$  et  $\nu$  et un prior sur  $\sigma^2$ .
- Même idée pour le SMC tempering.
- Appliquer le SMC tempering lorsque la dimension du modèle est grande.
- Rendre le SMC tempering adaptatif.

# Ouverture

